<pre>import jovian import torch.nn.functional as F from torchvision.datasets.utils import download_url from torchvision.datasets import ImageFolder from torch.utils.data import DataLoader import torchvision.transforms as tt from torch.utils.data import random_split from torch.utils import make_grid from torchvision.utils import make_grid from torchvision.transforms import ToTensor import matplotlib import matplotlib.pyplot as plt %matplotlib inline matplotlib.rcParams['figure.facecolor'] = '#ffffff'</pre> C:\Users\bonjo\miniconda3\lib\site-packages\tqdm\auto.py:22: TqdmWarning: IProgress not found. Please update jupyter and ipywidgets. See https://ipywidgets.readthedocs. stable/user_install.html
<pre>stable/user_install.html from .autonotebook import tqdm as notebook_tqdm import opendatasets as od dataset_url = 'https://www.kaggle.com/jutrera/stanford-car-dataset-by-classes-folder' od.download(dataset_url) Skipping, found downloaded files in ".\stanford-car-dataset-by-classes-folder" (use force=True to force download) from torch.utils.data import Dataset import os DATA_DIR_TRAIN = './stanford-car-dataset-by-classes-folder/car_data/car_data/train' train_classes = os.listdir(DATA_DIR_TRAIN) DATA_DIR_TEST = './stanford-car-dataset-by-classes-folder/car_data/car_data/test' test_classes = os.listdir(DATA_DIR_TEST)</pre>
<pre>train_classes[5:10], test_classes[5:10] (['Acura ZDX Hatchback 2012', 'AM General Hummer SUV 2000', 'Aston Martin V8 Vantage Convertible 2012', 'Aston Martin V8 Vantage Coupe 2012', 'Aston Martin Virage Convertible 2012'], ['Acura ZDX Hatchback 2012', 'AM General Hummer SUV 2000', 'Aston Martin V8 Vantage Convertible 2012', 'Aston Martin V8 Vantage Convertible 2012', 'Aston Martin V8 Vantage Coupe 2012', 'Aston Martin V8 Vantage Coupe 2012', 'Aston Martin Virage Convertible 2012']) def find_classes(dir): train_classes = os.listdir(dir)</pre>
<pre>train_classes.sort() train_class_to_idx = {train_classes[i]: i for i in range(len(train_classes))} return train_classes, train_class_to_idx test_class_to_idx = {test_classes[i]: i for i in range(len(test_classes))} return test_classes, test_class_to_idx train_classes, train_c_to_idx = find_classes(DATA_DIR_TRAIN) test_classes, test_c_to_idx = find_classes(DATA_DIR_TEST) len(train_classes), len(test_classes) (196, 196) def find_classes(dir): test_classes = os.listdir(dir)</pre>
<pre>test_classes.sort() test_classe_to_idx = {test_classes[i]: i for i in range(len(test_classes))} return test_classes, test_class_to_idx test_classes, test_c_to_idx = find_classes(DATA_DIR_TEST) def extract_class(Datasets, slice): count = 0 for vals in os.listdir(Datasets): print(vals) count+=1 if count>slice: break; extract_class(DATA_DIR_TRAIN, 10)</pre>
Acura Thtegra Type R 2001 Acura TL Sedan 2012 Acura TL Sedan 2012 Acura TS Sedan 2012 Acura TS Sedan 2012 Acura ZDX Hatchback 2012 AM General Hummer SUV 2000 Aston Martin V8 Vantage Convertible 2012 Aston Martin V8 Vantage Convertible 2012 Aston Martin Virage Convertible 2015 Aston Martin Virage Convertible 2016 Aston Martin Virage Conve
<pre>image, label = train_dataset[np.random.randint(len(train_dataset))] print('image_shape: ', image.shape, 'Label:',label) image_shape: torch.Size([3, 221, 441]) Label: 29 image_shape: torch.Size([3, 480, 640]) Label: 190 image_shape: torch.Size([3, 225, 300]) Label: 94 image_shape: torch.Size([3, 194, 259]) Label: 77 image_shape: torch.Size([3, 540, 900]) Label: 133 for _ in range (5): image_ label = test_dataset[np.random.randint(len(test_dataset))] print('image_shape:', image.shape, 'Label:',label) image_shape: torch.Size([3, 480, 640]) Label: 123 image_shape: torch.Size([3, 743, 1024]) Label: 188</pre>
image_shape: torch.Size([3, 124, 166]) Label: 66 image_shape: torch.Size([3, 435, 653]) Label: 46 2. Описание датасета Датасет состоит из 196 классов автомобилей с общим количеством изображений в 16185 штук, снятых сзади. Количество тренировочных и тестовых данных примерно равно (8144 тренировочных и 81 тестовых). Присутствуют категории "Make" (марка производителя), "Model" (модель), "Year" (год выпуска - прим. автора). Размер изображений - 360x240. Впервые датасет был представлен в 2017-м год статье, посвященной разработке сверточной нейронной сети для распознавания изображений (статья - https://arxiv.org/pdf/1702.01721.pdf). Сегодня этот датасет используется для проектирования спроецированных генеративно-состязательных сетей с быстрой сходимостью (https://arxiv.org/pdf/2111.01071.pdf). Суть таких сетей заключается в проецировании реальных и стенерированных изображений в фиксированное, предварительно подготовленное пространство объектов, таким образом улучшается качество изображений, повышается эффективность выборки и скорость конвертен Генеративно-состязательные сети нацелены на моделирование распределения данного обучающего набора данных. Генератор G сопоставляет скрытые векторы z , отобранные из простого распределения P_z (обычно нормального распределения), с соответствующими стенерированным выборками $G(z)$. Затем дискриминатор D нацелен на то, чтобы отличать реальные выборки $x \sim P_z$ стенерированных выборок $G(z) \sim P_G(z)$. Эта основная идея приводит к следующей формуле: $\min_G \max_{D} [E_x[\log D(x)] + E_z[\log(1 - D(G(z)))])$ Мы вводим набор проекторов объектов $\{P_z\}$, которые отображают реальные и стенерированные изображения во входное пространство дискриминатора. Таким образом, прогнозируемое обучение генеративно-состязательной сети может быть сформулировано следующим образом $\min_G \max_{D} [E_x[\log D(P_x(x))] + E_z[\log(1 - D_z(P_z(G(z))))])$
3. Пример данных с разметкой и загрузка тестового набора def show_example(img, label): print('Label: ', train_dataset.classes[label], "("+str(label)+")") plt.imshow(img.permute(1, 2, 0)) show_example(*train_dataset[np.random.randint(len(train_dataset))]) Label: Dodge Durango SUV 2012 (91) 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
1200 - 14
100 - 200 - 300 - 300 - 300 - 400 - 500 - 600 - 700
train_dataset = ImageFolder(DATA_DIR_TRAIN, transform = train_tfms) test_dataset = ImageFolder(DATA_DIR_TEST, transform = test_tfms) test_dataset.classes[42:47] ['Bentley Continental Supersports Conv. Convertible 2012', 'Bentley Mulsanne Sedan 2011', 'Bugatti Veyron 16.4 Convertible 2009', 'Bugatti Veyron 16.4 Coupe 2009', 'Buick Enclave SUV 2012'] len(train_dataset), len(test_dataset) (8144, 8041)
<pre>random_seed = 42 torch.manual_seed(random_seed); val_percent = 0.1 val_size = int(val_percent * len(train_dataset)) train_size = len(train_dataset) - val_size train_ds, val_ds = random_split(train_dataset, [train_size, val_size]) len(train_ds), len(val_ds) (7330, 814) !pip install jovianupgradequiet jovian.log_dataset(dataset_url = dataset_url, val_size = val_size, random_seed = random_seed)</pre>
<pre>[jovian] Dataset logged. batch_size = 128 train_dl = DataLoader(train_ds, batch_size, shuffle = True, num_workers = 4, pin_memory = True) val_dl = DataLoader(val_ds, batch_size * 2, num_workers = 4, pin_memory=True) def show_batch(dl): for images, labels in dl: fig, ax = plt.subplots(figsize = (12,6)) ax.set_xticks([]), ax.set_yticks([]) ax.inshow(make_grid(images, nrow=16).permute(1,2,0)) break show_batch(train_dl);</pre>
Clipping input data to the valid range for imshow with RGB data ([01] for floats or [0255] for integers).
show_batch(val_d1); Clipping input data to the valid range for imshow with RGB data ([01] for floats or [0255] for integers).
4. Пример применения готовой модели на данных
Произведем обучение на сверточной нейронной сети simple_model = nn.Sequential(
<pre>class ImageClassificationBase(nn.Module): def training_step(self, batch): images, labels = batch out = self(images)</pre>
<pre>def accuracy(outputs, labels): _, preds = torch.max(outputs, dim=1) return torch.tensor(torch.sum(preds == labels).item() / len(preds)) class StanfordCarsModel(ImageClassificationBase): definit(self): super()init() self.network = nn.Sequential(nn.Conv2d(3, 8, kernel_size=3, padding=1), nn.ReLU(), nn.ReLU(), nn.ReLU(), nn.MaxPool2d(2, 2), nn.Conv2d(16, 32, kernel_size=3, stride=1, padding=1), nn.ReLU(), nn.ReLU(),</pre>
nn.Conv2d(32, 32, kernel_size=3, stride=1, padding=1), nn.ReLU(), nn.MaxPoolzd(2, 2), nn.Conv2d(32, 64, kernel_size=3, stride=1, padding=1), nn.ReLU(), nn.Conv2d(64, 64, kernel_size=3, stride=1, padding=1), nn.ReLU(), nn.MaxPoolzd(2, 2), nn.Flatten(), nn.Linear(64*32*32, 1024), nn.ReLU(), nn.Linear(1024, 512), nn.ReLU(), nn.Linear(512, 196)) def forward(self, xb): return self.network(xb) model = StanfordCarsModel() #model for images, labels in train_d1:
<pre>print('images.shape:', images.shape) out = model(images) print('out.shape:', out.shape) print('out[0]:', out[0]) break images.shape: torch.Size([128, 3, 256, 256]) out.shape: torch.Size([128, 196]) out[0]: tensor([2.1798e-02, -1.5204e-02, 4.6250e-03, -3.0544e-02, -3.8073e-03,</pre>
-3.6612e-02, -2.0977e-02, 3.0480e-02, -5.0220e-02, -3.7621e-02, 3.091e-02, 4.611e-03, 1.9273e-02, -1.8635e-02, 2.1344e-02, 5.2925e-03, -3.1078e-02, 4.0403e-02, -3.3261e-02, 3.0229e-02, -3.3765e-02, -2.4655e-02, 3.1449e-02, 6.632e-04, 3.422e-02, 1.0025e-02, 8.2908e-03, 2.2984e-02, -1.6617e-02, 3.0227e-02, -4.1574e-02, 3.4534e-02, -3.529e-02, 4.3060e-02, 1.5835e-02, -4.1545e-02, 1.4652e-02, -7.6120e-03, -4.1957e-02, -1.31378e-02, -3.6676e-02, 9.090e-03, -4.1957e-02, -1.215e-02, -1.2339e-02, -1.7497e-02, -3.116e-02, -2.1516e-02, -1.2393e-02, -1.7497e-02, -3.116e-02, -2.1516e-02, -1.2393e-02, -1.7497e-02, -3.116e-02, -3.6516e-02, -1.5216e-02, -1.2392e-02, -1.7497e-02, -3.4116e-02, -3.6290e-03, -1.7497e-02, -3.7238e-02, -3.4217e-02, -1.7687e-02, -3.7238e-02, -4.2582e-02, -4.2586e-02, -1.530e-02, -1.530e-02, -1.530e-02, -1.530e-02, -1.7687e-02, -3.7382e-03, -2.4292e-02, -4.2586e-02, -3.2421e-02, -1.7687e-02, -3.3737e-02, -4.6522e-02, -2.6516e-02, -3.2957e-02, -1.748e-03, -4.091e-02, -1.7783e-02, -2.0604e-02, -1.2796e-03, -4.093e-02, -1.530e-02, -3.2956e-03, -3.2956e-03, -3.2956e-03, -3.2956e-03, -3.2956e-03, -3.2956e-03, -3.2956e-02, -3.4984e-02, -1.7738e-02, -2.1660e-03, -2.2660e-02, -3.2786e-03, -3.2956e-03, -3.2956e-03, -3.2956e-03, -3.2956e-03, -3.2956e-03, -3.2960e-02, -3.2980e-02, -3.2980e-02, -3.4836e-02, -3.2970e-02, -3.3957e-02, -3.4956e-03, -3.2424e-02, -3.2971e-02, -3.35957e-02, -3.0456e-03, -3.2424e-02, -3.2971e-02, -3.35957e-02, -3.0456e-03, -3.2424e-02, -3.2971e-02, -3.35957e-02, -3.0456e-02, -3.2970e-02, -3.5980e-02, -3.2970e-02, -3.5980e-02, -3.4980e-02, -3.5980e-02, -3.4980e-02,
<pre>4.3483e-02, -4.3460e-02, -3.1243e-02, -3.5551e-02, 1.1376e-02, -3.2017e-02, -3.6133e-02, -3.9473e-02, 6.1912e-04, 4.4205e-02, 7.4575e-03, 3.7374e-02, 3.1838e-02, -3.0728e-02, -2.653ae-02, -3.2724e-02, -4.0361e-02, 1.3341e-02, 4.1251e-02, -2.4923e-02, 1.6936e-02, -1.8192e-02, 1.7600e-02, -3.2066e-02, 2.3917e-02, 8.1950e-03], grad_fn=<selectbackward0>)</selectbackward0></pre> <pre> def get_default_device(): return torch.device('cpu') def to_device(data, device): if isinstance(data, (list,tuple)): return [to_device(x, device) for x in data] return data.to(device, non_blocking=True)</pre>
<pre>class DeviceDataLoader(): definit(self, dl, device): self.dl = dl self.device = device defiter(self): for b in self.dl: yield to_device(b, self.device) deflen(self): return len(self.dl) device = get_default_device() device(type='cpu')</pre>
train_dl = DeviceDataLoader(train_dl, device) val_dl = DeviceDataLoader(val_dl, device) to_device(model, device); from torch.utils.tensorboard import SummaryWriter import tensorflow as tf %reload_ext tensorboard Btorch.no_grad() def evaluate(model, val_loader): model.eval() outputs = [model.val_idation_step(batch) for batch in val_loader] return model.eval() outputs = [model.validation_expech_end(outputs) def fit(epochs, lr, model, train_loader, val_loader, opt_func=torch.optim.SGD): history = [] optimizer = opt_func(model.parameters(), lr) for epoch in range(epochs): # Training Phase model.trainin() train_losses = [] for batch in train_loader: loss = model.training.step(batch) writer = SummaryWriter() writer = SummaryWriter() writer = SummaryWriter() writer-add_scalar(*loss', loss, epoch) train_losses.appen(loss)
<pre>loss.backward() optimizer.step() optimizer.zero_grad() # Validation phase result = evaluate(model, val_loader) result['train_loss'] = torch.stack(train_losses).mean().item() model.epoch_end(epoch_result) history.append(result) return history model = to_device(StanfordCarsModel(), device) evaluate(model, val_dl) {'val_loss': 5.2801313400268555, 'val_acc': 0.0029296875}</pre>
<pre>num_epochs = 10 opt_func = torch.optim.Adam lr = 5e-2 jovian.reset() jovian.log_hyperparams({ 'num_epochs': num_epochs, 'opt_func': opt_funcname, 'batch_size': batch_size, 'lr': lr, }) [jovian] Hyperparams logged. history = fit(num_epochs, lr, model, train_dl, val_dl, opt_func)</pre>
Epoch [0], train_loss: 179070.6406, val_loss: 5.3159, val_acc: 0.0049 Epoch [1], train_loss: 5.2997, val_loss: 5.2999, val_acc: 0.0226 Epoch [2], train_loss: 5.2950, val_loss: 5.3001, val_acc: 0.0226 Epoch [3], train_loss: 5.2920, val_loss: 5.2961, val_acc: 0.0226 Epoch [4], train_loss: 5.2923, val_loss: 5.2935, val_acc: 0.0226 Epoch [5], train_loss: 5.2905, val_loss: 5.2956, val_acc: 0.0226 Epoch [6], train_loss: 5.2898, val_loss: 5.2956, val_acc: 0.0226 Epoch [7], train_loss: 5.2897, val_loss: 5.2952, val_acc: 0.0226 Epoch [8], train_loss: 5.2910, val_loss: 5.2956, val_acc: 0.0226 Epoch [9], train_loss: 5.2910, val_loss: 5.2929, val_acc: 0.0226 Epoch [9], train_loss: 5.2910, val_loss: 5.2929, val_acc: 0.0226 Ipovian.reset() Ipovian.log_hyperparams({
<pre>'batch_size': batch_size, 'lr': lr, }) [jovian] Hyperparams logged. test_dataset = ImageFolder(DATA_DIR_TEST, transform = test_tfms) def predict_image(img, model): # Convert to a batch of 1 xb = to_device(img.unsqueeze(0), device) # Get predictions from model yb = model(xb) # Pick index with highest probability _, preds = torch.max(yb, dim=1) # Retrieve the class label</pre>
<pre># Retrieve the class label return test_dataset.classes[preds[0].item()] img, label = test_dataset[np.random.randint(len(test_dataset))] plt.imshow(img.permute(1, 2, 0)) print('Label:', test_dataset.classes[label], ', Predicted:', predict_image(img, model)) Clipping input data to the valid range for imshow with RGB data ([01] for floats or [0255] for integers). Label: Chevrolet Silverado 1500 Regular Cab 2012 , Predicted: GMC Savana Van 2012</pre>
150 - 200 - 250
С помощью Plotly было отображено распределение количества изображений машин для каждого класса. [21]: import plotly.express as px import pandas as pd [22]: df = pd.read_csv('names.csv') df.head() [22]:
10 5
0 30 32 34 36 38 40 42 44 46 Images(qty) 6. TensorBoard Вывод графиков осуществляется с помощью команды: tensorboardlogdir=runs На графике рассматривалась динамика функции потерь ТensorBoard SCALARS TIME SERIES INACTIVE ① UPLOAD ② ② ②
☐ Show data download links ☐ Ignore outliers in chart scaling Tooltip sorting method: default ✓ Filter tags (regular expressions supported) Loss